

Université Euro-Méditerranéenne de Fès

Ingénierie Digitale et Intelligence Artificielle

Spécialité Intelligence Artificielle

Rapport de Stage

Détection et Classification Automatique des Bâtiments Endommagés à partir d'Images Satellitaires par Deep Learning

Organisme d'accueil :

Fonds de Solidarité contre les Événements
Catastrophiques (FSEC)

Encadrante :

Mme Lamya AMGHAR

Réalisé par

Firdawss EL HAYOUNI

Ikrame CHENNOUF

Année Universitaire 2025–2026

Dédicace

Nous dédions ce modeste travail :À nos très chers parents, pour leur amour inconditionnel,leurs sacrifices sans limites et leur soutien indéfectible tout au long de notre parcours. Aucun mot ne saurait exprimer la profondeur de notre gratitude.À nos familles,pour leur présence,leur encouragement et les valeurs qu'elles nous ont transmises.À nos enseignants,qui ont éveillé en nous la curiosité scientifique et nous ont armées des connaissances nécessaires pour relever les défis de demain.À toutes les personnes qui croient en la force de l'intelligence artificielle au service de l'humanité. Que ce travail soit le témoignage de notre reconnaissance et le premier pas d'un long chemin.

Remerciements

Nous tenons à exprimer notre profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce travail. Nous adressons nos remerciements les plus sincères à Madame Lamy AMGHAR, notre encadrante au sein du Fonds de Solidarité contre les Événements Catastrophiques (FSEC), pour sa disponibilité, sa bienveillance et la qualité de son encadrement. Ses conseils avisés et son suivi rigoureux ont été déterminants dans l'avancement de ce projet. Nous remercions chaleureusement la direction et l'ensemble du personnel du FSEC pour leur accueil, leur professionnalisme et les conditions de travail qu'ils nous ont offertes. Cette expérience au sein d'un organisme à fort impact sociétal a été particulièrement enrichissante. Nous exprimons également notre reconnaissance à l'ensemble du corps enseignant de l'Université Euro-Méditerranéenne de Fès (UEMF), et plus particulièrement aux professeurs de la filière Ingénierie Digitale et Intelligence Artificielle, pour la qualité de la formation dispensée et pour nous avoir préparées à affronter les défis du monde professionnel. Enfin, nous remercions nos familles et nos proches pour leur soutien moral constant et leurs encouragements tout au long de notre cursus académique.

Résumé

Ce rapport présente les travaux réalisés dans le cadre de notre stage effectué au sein du Fonds de Solidarité contre les Événements Catastrophiques (FSEC), organisme marocain chargé de la gestion, de l'évaluation et de l'indemnisation des dommages causés par les catastrophes naturelles.

L'objectif principal de ce projet est de développer une solution intelligente et automatisée basée sur les techniques du Deep Learning permettant de détecter et de classifier les bâtiments endommagés à partir d'images satellitaires acquises avant et après une catastrophe naturelle. Une telle approche vise à accélérer le processus d'évaluation des dégâts en fournissant des informations fiables et rapidement exploitables pour les organismes de gestion des risques et de secours.

Dans un premier temps, une étude bibliographique approfondie a été menée afin de comprendre les enjeux liés à la gestion des catastrophes naturelles, à la télédétection satellitaire et aux méthodes d'intelligence artificielle appliquées à l'analyse d'images. Cette phase a également permis d'étudier les principales architectures de Deep Learning utilisées pour la segmentation et l'évaluation des dommages, notamment les réseaux de neurones convolutifs (CNN), U-Net, Siamese U-Net, BDANet ainsi que les architectures récentes basées sur les Transformers.

Par la suite, une analyse détaillée du dataset xBD a été réalisée. Cette étape a porté sur l'étude de la structure des données, des annotations au format JSON, des masques de segmentation ainsi que sur l'analyse statistique de la distribution des classes de dommages. Les différentes opérations de prétraitement nécessaires à l'exploitation des données ont également été mises en œuvre.

Dans le cadre de la phase expérimentale, plusieurs approches ont été étudiées pour la détection et la classification des dommages. Le modèle retenu repose sur un backbone DINOv3 associé à une architecture siamoise permettant d'exploiter conjointement les images pré-catastrophe et post-catastrophe. Les performances du modèle ont été évaluées sur différentes scènes issues du dataset xBD à l'aide de métriques telles que l'Accuracy et le F1-score.

Enfin, une application interactive a été développée afin de faciliter l'utilisation du modèle.

Cette application permet de charger les images satellitaires ainsi que les annotations associées, de générer automatiquement les prédictions de dommages et de visualiser les résultats obtenus sous une forme intuitive.

Les travaux réalisés démontrent l'intérêt des techniques de Deep Learning et de la télédétection pour l'automatisation de l'évaluation des dommages post-catastrophe, ouvrant ainsi la voie à des solutions d'aide à la décision plus rapides et plus efficaces.

Introduction générale

Ce rapport présente les travaux réalisés dans le cadre de notre stage effectué au sein du Fonds de Solidarité contre les Événements Catastrophiques (FSEC), organisme marocain chargé de la gestion, de l'évaluation et de l'indemnisation des dommages résultant des catastrophes naturelles.

Face à l'augmentation de la fréquence et de l'intensité des catastrophes naturelles à travers le monde, l'évaluation rapide et précise des dommages constitue un enjeu majeur pour les autorités et les organismes de gestion des risques. Dans ce contexte, l'imagerie satellitaire associée aux techniques d'intelligence artificielle offre de nouvelles perspectives pour automatiser l'analyse des zones sinistrées et accélérer les opérations de secours et d'indemnisation.

L'objectif principal de ce projet est de développer une solution intelligente basée sur les techniques du Deep Learning permettant de détecter et de classifier automatiquement les bâtiments endommagés à partir d'images satellitaires acquises avant et après une catastrophe naturelle. Cette approche vise à fournir une aide à la décision rapide, fiable et efficace pour l'évaluation des dégâts post-catastrophe.

Afin de répondre à cette problématique, une étude bibliographique a été menée sur les concepts fondamentaux liés à la gestion des catastrophes naturelles, à la télédétection satellitaire ainsi qu'aux méthodes d'intelligence artificielle appliquées à l'analyse d'images. Les principales architectures utilisées dans la littérature pour la segmentation et l'évaluation des dommages ont également été étudiées, notamment les réseaux de neurones convolutionnels (CNN), U-Net, Siamese U-Net, BDANet ainsi que les architectures récentes basées sur les Transformers.

Le projet s'appuie sur le dataset xBD, l'une des plus importantes bases de données dédiées à l'évaluation des dommages causés par les catastrophes naturelles. Une analyse détaillée de sa structure, de ses annotations au format JSON, de ses masques de segmentation ainsi que de la distribution des différentes classes de dommages a été réalisée. Cette étape a permis d'identifier plusieurs défis liés à la qualité des données et au déséquilibre des classes.

Dans la phase expérimentale, différentes approches de Deep Learning ont été étudiées et

prises en œuvre pour la détection et la classification des dommages. Une attention particulière a été portée à l'exploitation conjointe des images pré-catastrophe et post-catastrophe afin d'améliorer la qualité des prédictions. Les performances obtenues ont été évaluées à l'aide de métriques quantitatives telles que l'Accuracy et le F1-score.

Enfin, une application interactive a été développée afin de faciliter l'utilisation du modèle et la visualisation des résultats. Cette application permet de charger les images satellitaires et les annotations associées, d'effectuer automatiquement les prédictions et d'afficher les résultats sous une forme claire et intuitive.

Les travaux réalisés mettent en évidence le potentiel des techniques de Deep Learning et de la télédétection pour l'automatisation de l'évaluation des dommages post-catastrophe. Ils ouvrent également la voie à des solutions d'aide à la décision plus rapides et plus performantes pour les organismes chargés de la gestion des risques et de l'indemnisation.

Table des matières

Introduction générale	5
1 Présentation de l'organisme d'accueil	12
1.1 Historique du FSEC	12
1.2 Missions du FSEC	12
1.3 Gouvernance du FSEC	13
1.4 Organisation interne du FSEC	13
1.5 Projets réalisés par le FSEC	14
1.6 Chiffres clés du FSEC	14
2 Contexte général et étude bibliographique	15
2.1 Introduction	15
2.1.1 Enjeux généraux	15
2.1.2 Importance pour le FSEC	16
2.2 Gestion des catastrophes naturelles	16
2.2.1 Définition et types de catastrophes	16
2.2.2 Impact des catastrophes sur les infrastructures	17
2.2.3 Importance de l'évaluation rapide des dommages	17
2.3 Détection des dommages aux bâtiments après catastrophe	18
2.3.1 Méthodes traditionnelles d'évaluation	18
2.3.2 Limites des approches conventionnelles	18
2.3.3 Intérêt de l'automatisation	19
2.4 Télédétection et imagerie satellitaire	19
2.4.1 Contribution de l'imagerie satellitaire à la gestion des catastrophes	19
2.4.2 Rôle de la télédétection	20
2.5 Imagerie radar : Sentinel-1	20
2.5.1 Principe du radar SAR	20
2.5.2 Caractéristiques du satellite Sentinel-1	21
2.5.3 Avantages et limites	21
2.6 Imagerie optique : Sentinel-2	21
2.6.1 Principe de l'imagerie optique	21
2.6.2 Caractéristiques du satellite Sentinel-2	22

2.6.3	Avantages et limites	22
2.7	Intelligence artificielle pour l'analyse d'images satellitaires	22
2.7.1	Intelligence artificielle	22
2.7.2	Machine Learning	23
2.7.3	Deep Learning	23
2.7.4	Réseaux de neurones convolutionnels (CNN)	24
2.7.5	Vision Transformers (ViT)	24
2.8	Modèles avancés pour l'analyse d'images satellitaires	25
2.8.1	DINOv3	25
2.8.2	UperNet	25
2.9	Segmentation d'images	26
2.9.1	Définition	26
2.9.2	Classification, détection et segmentation	27
2.9.3	Segmentation sémantique	27
2.9.4	Segmentation d'instances	28
2.9.5	Segmentation panoptique	29
2.10	Travaux existants sur la détection des dommages aux bâtiments	29
2.10.1	Approches basées sur les réseaux convolutifs (CNN)	29
2.10.2	Approches de segmentation dédiées à l'évaluation des dommages	30
2.10.3	BDANet : Building Damage Assessment Network	30
2.10.4	Approches basées sur les Transformers	31
2.10.5	Comparaison des approches existantes	31
3	Données et méthodologie proposée	33
3.1	Introduction	33
3.1.1	Présentation du dataset xBD / xView2	33
3.1.2	Structure du dataset	34
3.1.3	Classes de dommages	35
3.1.4	Répartition des données	36
3.2	Prétraitement des données	37
3.2.1	Nettoyage des données	37
3.2.2	Redimensionnement	37
3.2.3	Normalisation	37
3.2.4	Génération des masques	38
3.2.5	Gestion du déséquilibre des classes	39
3.3	Architecture proposée	39
3.3.1	Présentation générale	39
3.3.2	Backbone DINOv3	40
3.3.3	Décodeur UperNet	40

3.3.4	Pipeline de prédiction	41
3.3.5	Calibration des probabilités	41
3.4	Métriques d'évaluation	42
3.4.1	Accuracy	42
3.4.2	F1-Score	42
4	Résultats expérimentaux et application développée	44
4.1	Environnement expérimental	44
4.2	Bibliothèques utilisées	44

Table des figures

2.1	Exemple de segmentation sémantique appliquée à l'évaluation des dommages post-catastrophe. Les images pré-catastrophe et post-catastrophe sont utilisées pour produire une carte de segmentation où chaque pixel est associé à une classe de dommage : No Damage, Minor Damage, Major Damage ou Destroyed.	28
3.1	Exemple d'une scène du dataset xBD. Les données comprennent une image pré-catastrophe, une image post-catastrophe, une carte des niveaux de dommages ainsi que les empreintes des bâtiments annotées.	34
3.2	Illustration des différentes classes de dommages présentes dans le dataset xBD. Chaque couleur représente un niveau de dommage associé aux bâtiments après une catastrophe naturelle.	36

Liste des tableaux

2.1	Comparaison entre classification, détection et segmentation	27
2.2	Comparaison des principales approches étudiées	32
3.1	Classes de dommages utilisées dans les masques xBD	39

Chapitre 1

Présentation de l'organisme d'accueil

1.1 Historique du FSEC

Le Fonds de Solidarité contre les Événements Catastrophiques (FSEC) a été créé dans le cadre de la stratégie nationale marocaine de gestion des risques liés aux catastrophes naturelles. Sa mise en place répond à la nécessité de renforcer la protection des populations face aux conséquences humaines et matérielles des événements catastrophiques tels que les séismes, les inondations, les glissements de terrain ou encore les tempêtes.

Avant la création du FSEC, l'indemnisation des victimes dépendait essentiellement des contrats d'assurance privés, ce qui laissait une grande partie de la population sans protection suffisante. Afin de combler cette lacune, le Royaume du Maroc a instauré un mécanisme solidaire permettant d'assurer une couverture plus large des citoyens touchés par des catastrophes naturelles.

Le FSEC constitue ainsi un pilier essentiel du dispositif national de gestion des catastrophes. Son rôle est d'apporter une assistance financière aux personnes sinistrées et de contribuer au renforcement de la résilience nationale face aux risques majeurs. Aujourd'hui, le Fonds participe activement au développement de solutions innovantes intégrant les technologies numériques, la télédétection et l'intelligence artificielle afin d'améliorer les processus d'évaluation et de gestion des dommages.

1.2 Missions du FSEC

Le Fonds de Solidarité contre les Événements Catastrophiques a pour mission principale d'assurer une protection financière aux victimes d'événements catastrophiques et de soutenir les actions visant à améliorer la gestion des risques au Maroc.

Ses principales missions sont les suivantes :

- Assurer l'indemnisation des victimes non couvertes par des contrats d'assurance ;
- Participer à l'évaluation rapide et rigoureuse des dommages causés par les catastrophes naturelles ;
- Fournir un soutien financier aux populations sinistrées ;
- Contribuer à la mise en œuvre des dispositifs nationaux de gestion des catastrophes ;
- Développer des outils d'aide à la décision destinés aux autorités compétentes ;
- Encourager l'utilisation des nouvelles technologies pour améliorer la prévention et la gestion des risques ;
- Renforcer la résilience du Royaume face aux événements catastrophiques.

Le FSEC intervient en complément du système d'assurance privé afin de garantir une meilleure protection des populations les plus vulnérables.

1.3 Gouvernance du FSEC

Le FSEC est un établissement public administratif placé sous la tutelle de l'État et disposant d'une autonomie financière. Sa gouvernance repose sur une organisation garantissant la transparence, la rigueur et l'efficacité dans la gestion des ressources mobilisées.

Le Conseil d'Administration est présidé par le Chef du Gouvernement et réunit plusieurs représentants d'institutions publiques et du secteur des assurances. Parmi les membres figurent notamment des représentants du Ministère de l'Économie et des Finances, du Ministère de l'Intérieur, du Ministère de la Santé, du Ministère de l'Habitat, de la Fédération Marocaine de l'Assurance ainsi que de l'Autorité de Contrôle des Assurances et de la Prévoyance Sociale (ACAPS).

Cette structure est complétée par des comités spécialisés, notamment un comité d'audit et des risques ainsi qu'un comité de stratégie et d'investissement, chargés d'assurer le suivi des activités et la bonne gouvernance du Fonds.

1.4 Organisation interne du FSEC

L'organisation interne du FSEC repose sur plusieurs unités fonctionnelles travaillant de manière coordonnée afin d'assurer l'accomplissement de ses missions.

Les principales activités du Fonds concernent la gestion administrative et financière, l'évaluation des dommages causés par les catastrophes, le traitement des demandes d'indemnisation, la gestion des risques ainsi que le développement de projets stratégiques liés à l'innovation technologique.

Le FSEC collabore également avec plusieurs organismes nationaux et internationaux spécialisés dans la gestion des risques, la télédétection, l'assurance et la modélisation des catastrophes naturelles. Cette coopération permet d'améliorer continuellement les méthodes d'évaluation des dommages et les mécanismes de compensation.

1.5 Projets réalisés par le FSEC

Dans le cadre de sa stratégie de modernisation, le FSEC a lancé plusieurs projets visant à renforcer la connaissance des risques et à améliorer les mécanismes de gestion des catastrophes.

Parmi les projets majeurs figurent :

- Le programme MNHPRA consacré à la modélisation probabiliste des risques de catastrophes naturelles au Maroc ;
- Le projet ICAT dédié à la modélisation des risques d'inondation à travers des approches probabilistes et déterministes ;
- Le développement d'une plateforme numérique d'indemnisation permettant d'accélérer le traitement des dossiers des sinistrés ;
- La mise en place d'une plateforme de déclaration rapide des catastrophes en partenariat avec le CRTS et ICEYE ;
- Le développement de solutions innovantes basées sur l'imagerie satellitaire et l'intelligence artificielle pour l'évaluation automatisée des dommages.

Ces projets traduisent la volonté du FSEC d'intégrer les technologies les plus récentes afin d'améliorer l'efficacité de ses interventions.

1.6 Chiffres clés du FSEC

Le Fonds de Solidarité contre les Événements Catastrophiques constitue aujourd'hui un acteur majeur du dispositif national de gestion des catastrophes au Maroc.

Son financement provient principalement d'une taxe parafiscale de 1% prélevée sur les contrats d'assurance non-vie, générant environ 26 millions de dollars américains par an. Ces ressources permettent de financer les mécanismes d'indemnisation des victimes et de soutenir les différents programmes de gestion des risques.

Le FSEC intervient sur l'ensemble du territoire national et participe activement à la gestion des conséquences des événements catastrophiques majeurs. Son action s'inscrit dans une démarche durable visant à renforcer la résilience des populations et à améliorer la capacité du Maroc à faire face aux catastrophes naturelles.

Chapitre 2

Contexte général et étude bibliographique

2.1 Introduction

Les catastrophes naturelles telles que les séismes, les tsunamis, les inondations, les tempêtes ou encore les glissements de terrain provoquent chaque année des pertes humaines et matérielles considérables à travers le monde. Au-delà de leur impact sur les populations, ces événements engendrent également d'importantes conséquences économiques et sociales.

Dans les heures qui suivent une catastrophe, l'évaluation rapide des dommages constitue une étape essentielle pour organiser les opérations de secours, estimer les pertes et orienter les décisions des autorités compétentes. Toutefois, les méthodes traditionnelles d'évaluation reposent généralement sur des inspections de terrain qui nécessitent un temps important et la mobilisation de nombreuses ressources humaines.

Les progrès récents réalisés dans les domaines de la télédétection satellitaire et de l'intelligence artificielle offrent aujourd'hui de nouvelles possibilités pour automatiser l'analyse des zones sinistrées. Dans ce contexte, le présent projet vise à développer une solution basée sur le Deep Learning permettant de détecter et de classifier automatiquement les bâtiments endommagés à partir d'images satellitaires acquises avant et après une catastrophe naturelle.

2.1.1 Enjeux généraux

L'évaluation des dommages constitue l'une des premières étapes du processus de gestion post-catastrophe. Elle permet d'identifier les zones les plus touchées, de prioriser les interventions d'urgence et d'estimer les ressources nécessaires aux opérations de secours et de reconstruction.

Les méthodes conventionnelles reposent principalement sur des inspections de terrain réalisées par des experts. Bien que ces approches fournissent des informations précises, elles présentent plusieurs limites, notamment lorsqu'il s'agit d'évaluer rapidement de vastes zones géographiques ou des régions difficilement accessibles après une catastrophe.

Dans ce contexte, l'utilisation de l'imagerie satellitaire apparaît comme une solution particulièrement intéressante. Grâce à sa couverture spatiale étendue et à sa disponibilité rapide après un événement, elle permet d'obtenir une vision globale des zones affectées.

Associées aux techniques de Deep Learning, ces données offrent la possibilité d'automatiser la détection et la classification des dommages avec un niveau de précision élevé, tout en réduisant considérablement les délais d'analyse.

2.1.2 Importance pour le FSEC

Le Fonds de Solidarité contre les Événements Catastrophiques (FSEC) a pour mission de contribuer à l'indemnisation des victimes de catastrophes naturelles et de participer aux mécanismes nationaux de gestion des risques.

Dans ce cadre, l'accès rapide à des informations fiables concernant l'étendue des dégâts représente un enjeu majeur. Une évaluation précise des dommages permet non seulement d'améliorer la planification des interventions d'urgence, mais également d'optimiser les processus d'estimation des pertes et d'indemnisation.

Le développement d'une solution automatisée basée sur l'intelligence artificielle constitue ainsi un levier important pour renforcer l'efficacité opérationnelle du FSEC. En exploitant les images satellitaires et les techniques avancées de Deep Learning, il devient possible d'obtenir des évaluations plus rapides, plus homogènes et potentiellement plus précises que les méthodes traditionnelles.

Ce projet s'inscrit donc pleinement dans la stratégie de modernisation du FSEC et dans sa volonté d'intégrer les nouvelles technologies au service de la gestion des catastrophes naturelles.

2.2 Gestion des catastrophes naturelles

2.2.1 Définition et types de catastrophes

Les catastrophes naturelles sont des événements d'origine naturelle susceptibles de provoquer des pertes humaines, des dommages matériels importants ainsi que des perturbations économiques et sociales. Elles surviennent généralement de manière soudaine et peuvent

affecter une région limitée ou s'étendre à de vastes territoires.

On distingue plusieurs catégories de catastrophes naturelles. Les catastrophes géologiques regroupent notamment les séismes, les tsunamis et les glissements de terrain. Les catastrophes hydrologiques comprennent les inondations et les crues. Les catastrophes météorologiques englobent les tempêtes, les cyclones, les ouragans et les tornades. Enfin, les sécheresses et les vagues de chaleur constituent également des phénomènes naturels pouvant avoir des conséquences importantes sur les populations et les infrastructures.

Au cours des dernières décennies, l'augmentation de la fréquence et de l'intensité de certains phénomènes extrêmes a renforcé l'importance des systèmes de prévention, de surveillance et de gestion des catastrophes.

2.2.2 Impact des catastrophes sur les infrastructures

Les catastrophes naturelles ont des conséquences directes sur les infrastructures essentielles au fonctionnement des sociétés. Les bâtiments résidentiels, les établissements scolaires, les hôpitaux, les réseaux routiers, les ponts ainsi que les infrastructures de communication peuvent subir des dommages partiels ou complets.

Les séismes provoquent fréquemment l'effondrement de bâtiments et la détérioration des ouvrages d'art. Les inondations peuvent endommager les habitations, les routes et les réseaux électriques. Les tempêtes et les cyclones causent souvent des destructions importantes au niveau des toitures, des structures et des réseaux de transport.

Ces dommages entraînent non seulement des pertes économiques considérables, mais compliquent également les opérations de secours et le retour à une situation normale pour les populations affectées. L'identification rapide des infrastructures endommagées constitue donc une étape essentielle dans les opérations de gestion post-catastrophe.

2.2.3 Importance de l'évaluation rapide des dommages

Après une catastrophe naturelle, l'évaluation rapide des dommages représente une étape cruciale pour les organismes de gestion des risques et les autorités publiques. Elle permet d'identifier les zones les plus touchées, d'estimer l'ampleur des dégâts et de définir les priorités d'intervention.

Les méthodes traditionnelles reposent principalement sur des inspections de terrain réalisées par des experts. Bien que précises, ces approches nécessitent un temps important et mobilisent de nombreuses ressources humaines et matérielles. Dans le cas de catastrophes affectant de vastes zones géographiques, ces inspections peuvent devenir particulièrement difficiles à mettre en œuvre.

L'utilisation des technologies de télédétection et des images satellitaires permet aujourd'hui d'accélérer considérablement ce processus. Associées aux techniques d'intelligence artificielle et de Deep Learning, elles offrent la possibilité d'automatiser la détection des dommages et de produire rapidement des cartes d'évaluation des dégâts. Ces informations facilitent la prise de décision, l'organisation des secours et les procédures d'indemnisation des victimes.

2.3 Détection des dommages aux bâtiments après catastrophe

2.3.1 Méthodes traditionnelles d'évaluation

L'évaluation des dommages causés aux bâtiments après une catastrophe naturelle constitue une étape essentielle dans les opérations de gestion de crise. Traditionnellement, cette évaluation est réalisée à travers des inspections de terrain effectuées par des équipes d'experts, d'ingénieurs ou d'agents de protection civile. Ces équipes se déplacent sur les zones sinistrées afin d'observer directement l'état des infrastructures et d'estimer le niveau des dégâts subis.

Cette approche permet d'obtenir des informations détaillées sur les bâtiments touchés et de produire des rapports précis destinés aux autorités compétentes. Les données collectées servent notamment à organiser les opérations de secours, à estimer les pertes économiques et à faciliter les procédures d'indemnisation des victimes.

Par ailleurs, certaines évaluations peuvent également s'appuyer sur des photographies aériennes, des relevés topographiques ou des images acquises par drones afin de compléter les observations réalisées sur le terrain.

2.3.2 Limites des approches conventionnelles

Malgré leur précision, les méthodes traditionnelles présentent plusieurs limitations importantes. La réalisation d'inspections de terrain nécessite généralement un temps considérable ainsi qu'une mobilisation importante de ressources humaines et matérielles. Lorsque la catastrophe affecte une vaste région géographique, l'évaluation complète des dommages peut prendre plusieurs jours, voire plusieurs semaines.

De plus, certaines zones touchées peuvent être difficilement accessibles en raison de l'effondrement des infrastructures routières, des inondations ou de conditions de sécurité défavorables. Ces contraintes ralentissent considérablement la collecte des informations et peuvent retarder la prise de décision.

Les méthodes manuelles sont également sujettes à une certaine variabilité liée à l'interprétation des experts. Les résultats obtenus peuvent ainsi présenter des différences selon l'expérience des évaluateurs ou les conditions d'observation sur le terrain.

2.3.3 Intérêt de l'automatisation

Face aux limites des approches conventionnelles, l'automatisation de la détection des dommages apparaît aujourd'hui comme une solution particulièrement prometteuse. Les progrès récents de la télédétection, de l'imagerie satellitaire et de l'intelligence artificielle permettent désormais d'analyser rapidement de grandes quantités de données géospatiales.

L'utilisation d'images satellitaires acquises avant et après une catastrophe offre la possibilité d'identifier automatiquement les changements observés au niveau des bâtiments. Associées aux techniques de Deep Learning, ces données permettent de détecter, localiser et classifier les dommages avec une précision de plus en plus élevée.

L'automatisation présente plusieurs avantages majeurs : elle réduit considérablement le temps nécessaire à l'évaluation des dégâts, permet de couvrir de vastes zones géographiques, diminue les coûts opérationnels et fournit des informations rapidement exploitables par les organismes de gestion des catastrophes. Ces bénéfices expliquent l'intérêt croissant porté aux systèmes intelligents d'évaluation automatique des dommages dans le domaine de la gestion des risques naturels.

2.4 Télédétection et imagerie satellitaire

2.4.1 Contribution de l'imagerie satellitaire à la gestion des catastrophes

L'imagerie satellitaire joue aujourd'hui un rôle essentiel dans la gestion des catastrophes naturelles. Grâce à sa capacité à observer de vastes zones géographiques en un temps réduit, elle permet aux autorités et aux organismes de secours d'obtenir rapidement une vision globale des zones affectées.

Les images acquises avant et après une catastrophe facilitent l'identification des changements survenus au niveau des infrastructures, des zones urbaines ou des espaces naturels. Elles sont utilisées pour localiser les régions les plus touchées, évaluer l'étendue des dégâts et orienter les opérations de secours.

Dans le domaine de l'évaluation des dommages aux bâtiments, l'imagerie satellitaire constitue une source d'information précieuse permettant de réduire les délais d'analyse tout en couvrant des zones parfois difficiles d'accès après une catastrophe.

2.4.2 Rôle de la télédétection

La télédétection désigne l'ensemble des techniques permettant d'acquérir des informations sur un objet ou une zone sans contact direct avec celui-ci. Dans le contexte de l'observation de la Terre, elle repose principalement sur l'utilisation de capteurs embarqués à bord de satellites ou d'aéronefs.

Ces capteurs enregistrent les interactions entre le rayonnement électromagnétique et la surface terrestre afin de produire des images exploitables pour différentes applications. La télédétection est largement utilisée dans les domaines de l'agriculture, de l'environnement, de l'aménagement du territoire ainsi que dans la gestion des risques naturels.

Après une catastrophe, les données de télédétection permettent de suivre l'évolution des événements, d'évaluer les dégâts causés aux infrastructures et d'apporter une aide précieuse à la prise de décision.

2.5 Imagerie radar : Sentinel-1

2.5.1 Principe du radar SAR

Le radar à synthèse d'ouverture (SAR, Synthetic Aperture Radar) est une technologie de télédétection active capable de produire des images de la surface terrestre indépendamment des conditions météorologiques et de l'éclairage solaire.

Contrairement aux capteurs optiques qui enregistrent la lumière réfléchie par les objets, le radar SAR émet ses propres ondes micro-ondes vers la surface terrestre puis mesure le signal rétrodiffusé. Cette caractéristique lui permet d'acquérir des images aussi bien de jour que de nuit et même en présence de nuages ou de précipitations.

Les images SAR sont particulièrement adaptées à la surveillance des catastrophes naturelles telles que les inondations, les glissements de terrain ou les séismes.

Il existe plusieurs satellites utilisant la technologie SAR, tels que Sentinel-1, RADARSAT, TerraSAR-X et ALOS PALSAR. Dans la suite de ce chapitre, nous nous intéresserons plus particulièrement à Sentinel-1, qui est largement utilisé dans les applications de surveillance environnementale et de gestion des catastrophes grâce à la disponibilité libre et gratuite de ses données.

2.5.2 Caractéristiques du satellite Sentinel-1

Sentinel-1 est une mission du programme européen Copernicus dédiée à l'observation radar de la Terre. La constellation est composée de satellites équipés d'un capteur radar SAR opérant dans la bande C.

Les satellites Sentinel-1 fournissent des données gratuites et accessibles à l'échelle mondiale. Ils offrent une couverture régulière de la surface terrestre avec une résolution adaptée aux applications de surveillance environnementale et de gestion des catastrophes.

Grâce à leur capacité d'acquisition tout temps et jour/nuit, les données Sentinel-1 sont largement utilisées pour la cartographie des inondations, le suivi des mouvements du sol et l'analyse des zones sinistrées.

2.5.3 Avantages et limites

Le satellite Sentinel-1 présente plusieurs avantages pour l'observation de la Terre. Il permet une acquisition régulière des données, offre une large couverture géographique et facilite le suivi des changements de surface après une catastrophe naturelle. De plus, les données Sentinel-1 sont librement accessibles dans le cadre du programme Copernicus.

Cependant, les images Sentinel-1 présentent également certaines limites. Leur interprétation est relativement complexe en raison du bruit speckle et des phénomènes de rétrodiffusion radar. Par ailleurs, leur exploitation nécessite généralement des étapes de prétraitement spécifiques ainsi qu'une expertise adaptée.

2.6 Imagerie optique : Sentinel-2

2.6.1 Principe de l'imagerie optique

L'imagerie optique repose sur l'enregistrement du rayonnement solaire réfléchi par la surface terrestre. Les capteurs optiques mesurent cette énergie dans différentes bandes spectrales afin de produire des images proches de la vision humaine ou mettant en évidence certaines caractéristiques physiques des objets observés.

Cette technologie permet d'obtenir des images riches en informations visuelles et particulièrement adaptées à l'identification des bâtiments, des routes, de la végétation et d'autres éléments présents à la surface terrestre.

Il existe plusieurs satellites d'observation reposant sur l'imagerie optique, tels que Landsat-8, Landsat-9, SPOT, WorldView ou encore Sentinel-2. Dans le cadre de ce projet, nous nous

intéresserons particulièrement au satellite Sentinel-2, largement utilisé pour l'observation de la Terre grâce à sa couverture multispectrale et à la disponibilité libre de ses données.

2.6.2 Caractéristiques du satellite Sentinel-2

Sentinel-2 est une mission du programme Copernicus dédiée à l'observation optique de la Terre. La constellation comprend deux satellites équipés d'un imageur multispectral capable d'acquérir des données dans plusieurs bandes spectrales allant du visible à l'infrarouge.

Les images Sentinel-2 offrent une résolution spatiale pouvant atteindre 10 mètres pour certaines bandes et sont disponibles gratuitement. Elles sont largement utilisées dans les domaines de l'agriculture, de la surveillance environnementale, de la cartographie et de la gestion des catastrophes.

2.6.3 Avantages et limites

Le satellite Sentinel-2 présente plusieurs avantages pour l'observation de la Terre. Grâce à ses 13 bandes spectrales et à sa résolution spatiale pouvant atteindre 10 mètres, il permet d'obtenir des images détaillées de la surface terrestre. Ces données facilitent l'identification des bâtiments, l'analyse de l'occupation du sol et le suivi des changements survenus après une catastrophe naturelle. De plus, les données Sentinel-2 sont librement accessibles dans le cadre du programme Copernicus.

Cependant, Sentinel-2 présente également certaines limites. La qualité des images peut être affectée par la présence de nuages, de brouillard ou d'autres conditions atmosphériques défavorables. Par ailleurs, l'acquisition des données dépend de l'éclairage solaire, ce qui peut limiter l'observation dans certaines situations. Ces contraintes peuvent réduire la disponibilité des images exploitables lors d'événements extrêmes.

2.7 Intelligence artificielle pour l'analyse d'images satellitaires

2.7.1 Intelligence artificielle

L'intelligence artificielle (IA) désigne l'ensemble des méthodes et des techniques permettant à une machine de reproduire certaines capacités cognitives habituellement associées à l'intelligence humaine, telles que l'apprentissage, le raisonnement, la prise de décision ou encore la résolution de problèmes. Depuis plusieurs années, l'intelligence artificielle connaît un dé-

veloppement considérable grâce à l'augmentation de la puissance de calcul, à la disponibilité de grandes quantités de données et aux avancées algorithmiques.

Dans le domaine de l'observation de la Terre, l'intelligence artificielle est largement utilisée pour automatiser l'analyse des images satellitaires. Elle permet notamment de détecter des objets, de classifier des zones géographiques, de suivre l'évolution de phénomènes naturels et d'évaluer les dommages causés par des catastrophes naturelles.

2.7.2 Machine Learning

Le Machine Learning, ou apprentissage automatique, constitue une branche de l'intelligence artificielle qui permet aux systèmes informatiques d'apprendre à partir de données sans être explicitement programmés pour chaque tâche. Au lieu de suivre des règles prédéfinies, les algorithmes de Machine Learning identifient automatiquement des relations et des modèles présents dans les données afin de réaliser des prédictions ou des classifications.

Les principales approches du Machine Learning sont l'apprentissage supervisé, l'apprentissage non supervisé et l'apprentissage par renforcement. Dans le cadre de l'analyse d'images satellitaires, l'apprentissage supervisé est particulièrement utilisé puisque les modèles sont entraînés à partir d'exemples annotés permettant d'associer chaque image à une catégorie ou à une information spécifique.

2.7.3 Deep Learning

Le Deep Learning, ou apprentissage profond, représente une sous-catégorie du Machine Learning basée sur l'utilisation de réseaux de neurones artificiels comportant plusieurs couches de traitement. Ces réseaux sont capables d'apprendre automatiquement des représentations complexes à partir de grandes quantités de données.

Contrairement aux approches classiques nécessitant l'extraction manuelle de caractéristiques, le Deep Learning apprend directement les informations pertinentes à partir des données brutes. Cette capacité lui permet d'obtenir d'excellentes performances dans des domaines tels que la vision par ordinateur, la reconnaissance vocale ou le traitement du langage naturel.

Dans le contexte de l'analyse d'images satellitaires, le Deep Learning est devenu une technologie de référence pour la détection des bâtiments, la segmentation d'images et la classification des dommages après catastrophe.

2.7.4 Réseaux de neurones convolutionnels (CNN)

Les réseaux de neurones convolutionnels (Convolutional Neural Networks ou CNN) sont des architectures de Deep Learning spécialement conçues pour le traitement des images. Ils reposent sur l'utilisation d'opérations de convolution permettant d'extraire automatiquement des caractéristiques visuelles telles que les contours, les textures ou les formes présentes dans une image.

Les CNN sont constitués de plusieurs couches successives, notamment des couches de convolution, des fonctions d'activation et des couches de regroupement (pooling). Grâce à cette structure hiérarchique, les premières couches apprennent des caractéristiques simples tandis que les couches profondes capturent des informations plus complexes.

Les CNN ont largement contribué aux progrès récents de la vision par ordinateur et sont utilisés dans de nombreuses applications liées à la télédétection, notamment la classification d'images, la détection d'objets et la segmentation sémantique.

2.7.5 Vision Transformers (ViT)

Les Vision Transformers (ViT) constituent une nouvelle génération de modèles de Deep Learning inspirés de l'architecture Transformer initialement développée pour le traitement du langage naturel. Contrairement aux CNN qui analysent principalement les informations locales, les Vision Transformers sont capables de modéliser directement les relations globales entre différentes régions d'une image.

Le principe consiste à découper l'image en petits blocs appelés patches, qui sont ensuite traités comme des séquences de données par le mécanisme d'attention du Transformer. Cette approche permet au modèle d'exploiter efficacement les dépendances spatiales à grande échelle.

Les Vision Transformers ont démontré des performances remarquables dans plusieurs tâches de vision par ordinateur, notamment la classification, la détection d'objets et la segmentation d'images. Dans le domaine de la télédétection, ils sont de plus en plus utilisés pour l'analyse d'images satellitaires à haute résolution et constituent aujourd'hui une alternative performante aux architectures CNN traditionnelles.

Les avancées récentes des Vision Transformers ont conduit au développement de modèles de fondation spécialisés pour l'analyse d'images satellitaires, tels que DINOv3. Ces modèles pré-entraînés sur de très grands volumes de données offrent des représentations visuelles riches et robustes, particulièrement adaptées aux tâches de segmentation et de classification des dommages aux bâtiments après catastrophe.

2.8 Modèles avancés pour l'analyse d'images satellitaires

Les progrès récents de l'intelligence artificielle ont conduit à l'apparition de modèles de plus en plus performants pour l'analyse d'images satellitaires. Parmi ces modèles, les architectures basées sur les Transformers ont démontré leur capacité à capturer des informations spatiales complexes et à produire des représentations visuelles riches. Dans le cadre de ce projet, l'architecture retenue repose sur l'association du modèle DINOv3 comme extracteur de caractéristiques et du décodeur UperNet pour la segmentation et la classification des dommages aux bâtiments.

2.8.1 DINOv3

DINOv3 (Distillation with No Labels version 3) est un modèle de Vision Transformer (ViT) développé pour l'apprentissage de représentations visuelles à grande échelle. Contrairement aux approches traditionnelles nécessitant des annotations massives, DINOv3 repose sur un apprentissage auto-supervisé lui permettant d'extraire automatiquement des caractéristiques pertinentes à partir d'un grand volume d'images.

Le principe de DINOv3 consiste à apprendre des représentations robustes en comparant différentes vues d'une même image. Cette approche permet au modèle de capturer efficacement les structures, les textures et les relations spatiales présentes dans les images.

Dans le domaine de l'imagerie satellitaire, DINOv3 présente plusieurs avantages :

- Capacité à exploiter de grandes quantités de données non annotées ;
- Extraction de caractéristiques riches et généralisables ;
- Bonne adaptation aux images de télédétection ;
- Performances élevées sur les tâches de segmentation et de classification.

Dans notre projet, DINOv3 est utilisé comme backbone afin d'extraire les caractéristiques des images satellites acquises avant et après la catastrophe. Ces représentations servent ensuite d'entrée au décodeur chargé de produire la carte finale de dommages.

2.8.2 UperNet

UperNet (Unified Perceptual Parsing Network) est une architecture de segmentation sémantique conçue pour exploiter efficacement les caractéristiques extraites par des réseaux profonds ou des Vision Transformers.

L'architecture repose principalement sur deux mécanismes complémentaires :

- Le Feature Pyramid Network (FPN), permettant de fusionner les informations provenant de différents niveaux de résolution ;
- Le Pyramid Pooling Module (PPM), permettant de capturer le contexte global de l'image à plusieurs échelles.

Grâce à cette combinaison, UperNet est capable de prendre en compte à la fois les détails locaux et le contexte global de la scène observée.

Dans le cadre de notre projet, UperNet reçoit les caractéristiques produites par DINOv3 et génère une carte de segmentation indiquant le niveau de dommage associé à chaque bâtiment. Les classes considérées correspondent aux catégories du dataset xBD :

- No Damage ;
- Minor Damage ;
- Major Damage ;
- Destroyed.

L'association de DINOv3 et UperNet permet ainsi de bénéficier de représentations visuelles riches tout en produisant des prédictions précises pour la détection et la classification automatique des bâtiments endommagés après une catastrophe naturelle.

2.9 Segmentation d'images

La segmentation d'images constitue l'une des tâches fondamentales de la vision par ordinateur. Elle consiste à partitionner une image en plusieurs régions homogènes afin de faciliter son analyse et son interprétation. Contrairement aux méthodes de classification classiques qui attribuent une seule étiquette à l'ensemble de l'image, la segmentation permet d'obtenir une description détaillée du contenu visuel en associant une classe à chaque pixel.

Dans le domaine de la télédétection, la segmentation joue un rôle essentiel pour l'identification précise des objets présents dans les images satellitaires, tels que les bâtiments, les routes, les zones de végétation ou les zones affectées par une catastrophe naturelle. Elle constitue aujourd'hui un outil incontournable pour l'analyse automatisée des images à haute résolution.

2.9.1 Définition

La segmentation d'images est le processus consistant à diviser une image en plusieurs régions significatives partageant des caractéristiques communes telles que la couleur, la texture ou l'appartenance à une même catégorie d'objet.

L'objectif principal est d'attribuer à chaque pixel de l'image une étiquette représentant la classe à laquelle il appartient. Cette approche permet d'obtenir une localisation précise des objets et facilite l'extraction d'informations pertinentes à partir des données visuelles.

Dans le cadre de ce projet, la segmentation est utilisée pour identifier les bâtiments présents dans les images satellitaires et déterminer leur niveau de dommage après une catastrophe naturelle.

2.9.2 Classification, détection et segmentation

Les tâches d'analyse d'images peuvent être regroupées en trois catégories principales : la classification, la détection d'objets et la segmentation.

La classification consiste à attribuer une seule classe à l'image entière sans localiser les objets présents. La détection d'objets permet d'identifier les objets et de les localiser à l'aide de boîtes englobantes. Enfin, la segmentation fournit une description beaucoup plus précise en attribuant une classe à chaque pixel de l'image.

La Figure X illustre les différences entre ces trois approches.

Tâche	Sortie	Niveau de précision
Classification	Classe globale	Faible
Détection	Classe + boîte englobante	Moyen
Segmentation	Classe par pixel	Élevé

TABLE 2.1 – Comparaison entre classification, détection et segmentation

2.9.3 Segmentation sémantique

La segmentation sémantique consiste à attribuer une classe à chaque pixel de l'image sans distinguer les différentes instances d'un même objet.

Ainsi, tous les pixels appartenant à la classe « bâtiment » recevront la même étiquette, même s'ils correspondent à plusieurs bâtiments distincts. Cette approche permet d'obtenir une représentation détaillée de la scène tout en restant relativement simple à mettre en œuvre.

Dans le domaine de l'évaluation des dommages post-catastrophe, la segmentation sémantique est largement utilisée pour identifier les zones touchées et classer les bâtiments selon leur niveau de dommage.




FIGURE 2.1 – Exemple de segmentation sémantique appliquée à l'évaluation des dommages post-catastrophe. Les images pré-catastrophe et post-catastrophe sont utilisées pour produire une carte de segmentation où chaque pixel est associé à une classe de dommage : No Damage, Minor Damage, Major Damage ou Destroyed.

2.9.4 Segmentation d'instances

La segmentation d'instances va plus loin que la segmentation sémantique en distinguant individuellement chaque objet présent dans l'image.

Par exemple, si plusieurs bâtiments apparaissent dans une même scène, chacun d'eux recevra une identité propre même s'ils appartiennent tous à la classe « bâtiment ». Cette approche permet d'obtenir des informations plus détaillées sur chaque objet détecté.

La segmentation d'instances est particulièrement utile lorsque l'analyse nécessite une évaluation individuelle de chaque bâtiment ou infrastructure.

2.9.5 Segmentation panoptique

La segmentation panoptique combine les avantages de la segmentation sémantique et de la segmentation d'instances. Elle attribue simultanément une classe à chaque pixel et une identité unique à chaque objet présent dans l'image.

Cette approche fournit une compréhension complète de la scène observée en distinguant à la fois les catégories d'objets et leurs différentes occurrences.

Bien qu'elle soit plus complexe à mettre en œuvre, la segmentation panoptique représente aujourd'hui l'une des approches les plus avancées pour l'analyse d'images complexes, notamment dans le domaine de la vision par ordinateur et de la télédétection. Dans le cadre de ce projet, l'approche retenue relève principalement de la segmentation sémantique. Le modèle attribue à chaque pixel une classe correspondant à un niveau de dommage (No Damage, Minor Damage, Major Damage ou Destroyed), permettant ainsi de produire une cartographie détaillée des bâtiments affectés après une catastrophe naturelle.

2.10 Travaux existants sur la détection des dommages aux bâtiments

2.10.1 Approches basées sur les réseaux convolutifs (CNN)

Dans les premières recherches consacrées à l'évaluation automatique des dommages post-catastrophe, les réseaux de neurones convolutionnels (CNN) ont été largement utilisés pour exploiter les images satellitaires acquises avant et après une catastrophe. Ces approches reposent généralement sur l'extraction automatique de caractéristiques visuelles permettant d'identifier les changements observés sur les bâtiments.

Parmi les travaux les plus influents figure l'article *Building Damage Assessment from Satellite Imagery Using Convolutional Neural Networks*, développé dans le cadre du dataset xBD. Les auteurs proposent une architecture de type Siamese CNN capable d'analyser simultanément les images pré-catastrophe et post-catastrophe afin d'estimer le niveau de dommage subi par chaque bâtiment.

Les résultats obtenus montrent que les architectures convolutives permettent de détecter efficacement les changements structurels visibles sur les bâtiments. Cependant, ces méthodes rencontrent certaines difficultés lorsqu'il s'agit de capturer des relations spatiales complexes ou des dommages subtils répartis sur de larges zones.

2.10.2 Approches de segmentation dédiées à l'évaluation des dommages

Afin d'améliorer la précision de localisation des bâtiments endommagés, plusieurs travaux ont adopté des architectures de segmentation sémantique. Parmi elles, U-Net est devenue l'une des architectures les plus utilisées dans le domaine de la télédétection.

L'architecture U-Net repose sur une structure encodeur-décodeur associée à des connexions de saut (*skip connections*) permettant de préserver les détails spatiaux. Grâce à cette conception, elle est capable de produire des cartes de segmentation précises même avec un nombre limité de données annotées.

Dans le contexte de la détection des dommages, plusieurs variantes ont été proposées afin d'exploiter simultanément les images acquises avant et après catastrophe. Ces modèles permettent d'améliorer la détection des bâtiments affectés tout en conservant une bonne précision spatiale.

Malgré leurs performances intéressantes, les architectures basées uniquement sur les CNN restent limitées dans leur capacité à modéliser les dépendances globales présentes dans les images satellitaires de grande taille.

2.10.3 BDANet : Building Damage Assessment Network

Parmi les architectures récentes dédiées spécifiquement à l'évaluation des dommages, l'article *BDANet : Building Damage Assessment Network for Post-Earthquake Satellite Imagery* propose une approche avancée destinée à améliorer la classification des niveaux de dommages.

BDANet repose sur une architecture siamoise enrichie par plusieurs mécanismes innovants, notamment :

- **Multi-scale Feature Fusion (MFF)** pour combiner les informations extraites à différentes échelles ;
- **Cross-Directional Attention (CDA)** permettant de mieux mettre en évidence les changements entre les images pré- et post-catastrophe ;
- **CutMix Data Augmentation** afin d'améliorer la robustesse du modèle et de réduire les effets du déséquilibre des classes.

Les expérimentations réalisées sur le dataset xBD montrent que BDANet obtient de meilleures performances que plusieurs approches basées uniquement sur les CNN classiques.

L'étude de cette architecture a constitué une étape importante de notre travail bibliographique puisqu'elle illustre les techniques récentes utilisées pour améliorer l'évaluation automatique des dommages aux bâtiments.

2.10.4 Approches basées sur les Transformers

L'émergence des architectures Transformers a profondément transformé le domaine de la vision par ordinateur. Contrairement aux CNN, les Transformers utilisent des mécanismes d'attention permettant de capturer des relations à longue distance entre les différentes régions de l'image.

Parmi les modèles les plus récents figure **DINOv3 (Self-Supervised Vision Transformer)**, développé par Meta AI. Ce modèle est pré-entraîné sur un très grand volume d'images selon une stratégie d'apprentissage auto-supervisé, ce qui lui permet d'apprendre des représentations visuelles riches sans nécessiter d'annotations manuelles.

Dans le cadre de la télédétection, DINOv3 présente plusieurs avantages :

- Une meilleure compréhension du contexte global ;
- Une robustesse face aux variations d'échelle ;
- Une excellente capacité de généralisation ;
- Des performances élevées sur les tâches de segmentation.

Ces caractéristiques expliquent son adoption dans notre projet comme backbone principal pour l'extraction des caractéristiques visuelles.

2.10.5 Comparaison des approches existantes

Les travaux étudiés montrent une évolution progressive des méthodes utilisées pour l'analyse des dommages post-catastrophe. Les premières approches basées sur les CNN ont démontré l'intérêt du Deep Learning pour cette problématique, tandis que les architectures spécialisées telles que U-Net et BDANet ont permis d'améliorer la précision de la segmentation et de la classification.

Plus récemment, les modèles basés sur les Vision Transformers, notamment DINOv3, offrent une meilleure capacité de représentation grâce aux mécanismes d'attention globale. Associés à des décodeurs de segmentation performants tels que UperNet, ils constituent aujourd'hui l'une des solutions les plus prometteuses pour la détection et la classification automatique des bâtiments endommagés à partir d'images satellitaires.

C'est pour cette raison que notre travail s'oriente vers l'utilisation d'une architecture combinant **DINOv3 comme encodeur** et **UperNet comme décodeur de segmentation**, afin de bénéficier des avantages des Transformers tout en conservant une excellente précision spatiale.

Approche	Architecture	Avantages	Limites
CNN Siamese	CNN	Détection efficace des changements	Contexte global limité
U-Net	CNN Encodeur-Décodeur	Bonne précision spatiale	Difficulté à capturer les dépendances longues
BDANet	CNN + Attention	Bonne classification des dommages	Complexité plus élevée
DINOv3 + Uper-Net	Transformer + Décodeur	Contexte global, forte généralisation	Coût de calcul important

TABLE 2.2 – Comparaison des principales approches étudiées

Chapitre 3

Données et méthodologie proposée

3.1 Introduction

Après avoir présenté le contexte du projet ainsi que les principales approches utilisées dans la littérature, ce chapitre décrit les données exploitées et la méthodologie adoptée pour la détection et la classification automatique des bâtiments endommagés à partir d’images satellitaires.

Dans un premier temps, le dataset xBD utilisé dans cette étude est présenté en détail, notamment sa structure, ses annotations et les différentes classes de dommages qu’il contient. Dans un second temps, la méthodologie proposée est décrite, depuis le prétraitement des données jusqu’à l’architecture de Deep Learning retenue pour la segmentation et la classification des dommages.

3.1.1 Présentation du dataset xBD / xView2

Le dataset xBD (eXtended Building Damage Dataset), également connu sous le nom de xView2, constitue actuellement l’un des plus grands jeux de données publics dédiés à l’évaluation des dommages causés par les catastrophes naturelles à partir d’images satellitaires.

Développé dans le cadre du programme xView2 organisé par la Defense Innovation Unit (DIU), il a été conçu pour favoriser le développement de solutions basées sur l’intelligence artificielle destinées à l’analyse rapide des dégâts post-catastrophe.

Le dataset regroupe des images satellitaires haute résolution acquises avant et après différents événements naturels tels que les séismes, les tsunamis, les inondations, les incendies et les éruptions volcaniques.

Chaque paire d’images est accompagnée d’annotations détaillées permettant d’identifier les

bâtiments présents ainsi que leur niveau de dommage après la catastrophe.




FIGURE 3.1 – Exemple d’une scène du dataset xBD. Les données comprennent une image pré-catastrophe, une image post-catastrophe, une carte des niveaux de dommages ainsi que les empreintes des bâtiments annotées.

La Figure présente un exemple de données issues du dataset xBD. Chaque scène est constituée d’une image acquise avant la catastrophe, d’une image acquise après la catastrophe, d’une carte des dommages et des empreintes des bâtiments annotées. Cette structure permet d’exploiter simultanément les informations spatiales et temporelles afin de détecter et classer les bâtiments endommagés.

3.1.2 Structure du dataset

Le dataset xBD est organisé sous forme de paires d’images représentant une même zone géographique avant et après une catastrophe naturelle.

Pour chaque scène, plusieurs fichiers sont disponibles :

- Une image pré-catastrophe (*pre-disaster*);
- Une image post-catastrophe (*post-disaster*);
- Un fichier d’annotations au format JSON;
- Des masques de segmentation générés à partir des annotations.

Les annotations sont stockées sous forme de polygones représentant l’emprise de chaque bâtiment. Chaque polygone est associé à une classe indiquant son niveau de dommage après l’événement.

Cette structure permet de traiter simultanément les tâches de localisation des bâtiments et de classification des dommages.

3.1.3 Classes de dommages

Le dataset xBD définit quatre niveaux principaux de dommages pour les bâtiments affectés par une catastrophe :

- **No Damage** : le bâtiment ne présente aucun dommage visible;
- **Minor Damage** : le bâtiment présente des dommages légers sans compromettre sa structure globale;
- **Major Damage** : le bâtiment présente des dommages importants affectant une partie significative de sa structure;
- **Destroyed** : le bâtiment est totalement ou presque totalement détruit.

Lors de la préparation des données, une classe supplémentaire correspondant à l’arrière-plan (*Background*) est généralement introduite afin de représenter les pixels ne faisant partie d’aucun bâtiment.

Ainsi, les masques de segmentation utilisés dans ce projet comportent cinq classes : Background, No Damage, Minor Damage, Major Damage et Destroyed.




FIGURE 3.2 – Illustration des différentes classes de dommages présentes dans le dataset xBD. Chaque couleur représente un niveau de dommage associé aux bâtiments après une catastrophe naturelle.

La Figure illustre les différentes classes de dommages définies dans le dataset xBD. Chaque bâtiment est associé à une catégorie représentant son état après la catastrophe. Cette classification est utilisée comme vérité terrain lors de l’entraînement et de l’évaluation des modèles de Deep Learning.

3.1.4 Répartition des données

L’analyse statistique du dataset xBD révèle une distribution fortement déséquilibrée des classes de dommages.

La majorité des bâtiments appartient à la classe *No Damage*, tandis que les classes *Minor Damage*, *Major Damage* et particulièrement *Destroyed* sont moins représentées.

Ce déséquilibre constitue un défi important pour l’apprentissage des modèles de Deep Learning, car il peut entraîner une tendance à privilégier les classes majoritaires au détriment des classes minoritaires.

Afin d’évaluer correctement les performances du modèle, des métriques adaptées telles que le F1-score sont utilisées en complément de l’accuracy.

3.2 Prétraitement des données

Avant l'entraînement et l'évaluation du modèle, plusieurs opérations de prétraitement ont été appliquées aux données du dataset xBD afin de garantir leur compatibilité avec l'architecture utilisée et d'améliorer la qualité des résultats obtenus. Ces étapes concernent notamment le nettoyage des données, le redimensionnement des images, la normalisation des valeurs des pixels, la génération des masques de segmentation ainsi que l'analyse du déséquilibre des classes.

3.2.1 Nettoyage des données

Une première étape de nettoyage a été réalisée afin de vérifier l'intégrité des données du dataset xBD. Cette opération a consisté à identifier les images manquantes, les fichiers corrompus ainsi que les éventuelles incohérences entre les images pré-catastrophe, les images post-catastrophe et leurs annotations associées.

Les échantillons incomplets ou non exploitables ont été écartés afin de garantir la cohérence des données utilisées lors de l'entraînement et de l'évaluation du modèle.

3.2.2 Redimensionnement

Les images du dataset xBD possèdent des dimensions variables qui ne sont pas directement compatibles avec l'architecture utilisée. Afin d'uniformiser les données d'entrée, toutes les images pré-catastrophe et post-catastrophe ont été redimensionnées à une résolution fixe de 512×512 pixels.

Cette étape permet de réduire le coût computationnel tout en garantissant une taille d'entrée identique pour l'ensemble des échantillons traités par le modèle.

$$Image_{originale} \rightarrow 512 \times 512$$

3.2.3 Normalisation

Avant d'être introduites dans le modèle, les images ont été converties en valeurs flottantes comprises entre 0 et 1 puis normalisées à l'aide des paramètres ImageNet.

La normalisation permet d'harmoniser la distribution des données d'entrée et de faciliter le processus d'apprentissage du réseau de neurones. Elle contribue également à améliorer la stabilité numérique du modèle et à accélérer sa convergence.

Les valeurs utilisées sont :

$$Mean = (0.485, 0.456, 0.406)$$

$$Std = (0.229, 0.224, 0.225)$$

Ces valeurs correspondent respectivement aux moyennes et aux écarts-types des trois canaux RGB calculés sur le dataset ImageNet. Elles sont largement utilisées dans les modèles de vision par ordinateur pré-entraînés sur cette base de données.

La normalisation consiste à centrer et réduire les valeurs des pixels afin d'obtenir une distribution de données compatible avec celle utilisée lors du pré-entraînement du backbone DINOv3. Chaque pixel est transformé selon la relation suivante :

$$x_{norm} = \frac{x - Mean}{Std}$$

où :

- x représente la valeur du pixel après sa mise à l'échelle dans l'intervalle $[0, 1]$;
- $Mean$ représente la moyenne du canal considéré ;
- Std représente l'écart-type du canal considéré ;
- x_{norm} représente la valeur normalisée utilisée comme entrée du modèle.

Cette opération permet de réduire les différences d'échelle entre les canaux et d'améliorer les performances du réseau de neurones. La même normalisation a été appliquée aux images pré-catastrophe et post-catastrophe afin de garantir la cohérence des données fournies au modèle.

Cette normalisation est identique à celle utilisée lors du pré-entraînement du backbone DINOv3 sur des données normalisées selon les statistiques d'ImageNet.

3.2.4 Génération des masques

Le dataset xBD fournit les annotations des bâtiments sous forme de fichiers JSON contenant les polygones décrivant chaque bâtiment ainsi que son niveau de dommage.

À partir de ces annotations, des masques de segmentation ont été générés afin de fournir une vérité terrain exploitable par les modèles de Deep Learning. Chaque pixel du masque est associé à une classe représentant l'état du bâtiment observé après la catastrophe.

Les classes utilisées sont les suivantes :

Valeur	Classe
0	Background
1	No Damage
2	Minor Damage
3	Major Damage
4	Destroyed

TABLE 3.1 – Classes de dommages utilisées dans les masques xBD

Ces masques servent de vérité terrain lors de l’entraînement et de l’évaluation du modèle.

3.2.5 Gestion du déséquilibre des classes

L’analyse statistique du dataset xBD a mis en évidence un déséquilibre important entre les différentes classes de dommages. La majorité des bâtiments appartiennent à la classe *No Damage*, tandis que les classes *Minor Damage*, *Major Damage* et *Destroyed* sont beaucoup moins représentées.

Ce déséquilibre peut conduire le modèle à privilégier les classes majoritaires au détriment des classes rares. Afin de mieux comprendre cette problématique, une étude de la répartition des classes a été réalisée avant l’entraînement.

Cette analyse constitue une étape importante pour l’interprétation des performances obtenues et pour l’identification des difficultés liées à la classification des dommages.

3.3 Architecture proposée

3.3.1 Présentation générale

L’architecture proposée repose sur une approche de segmentation sémantique permettant de détecter et de classer automatiquement les bâtiments endommagés à partir d’images satellitaires acquises avant et après une catastrophe naturelle.

Le modèle combine un backbone Vision Transformer pré-entraîné, DINOv3, chargé d’extraire des représentations visuelles riches, avec un décodeur de segmentation UperNet chargé de produire une carte de prédiction à l’échelle des pixels.

Deux images satellitaires sont utilisées comme entrées : une image pré-catastrophe et une image post-catastrophe. Après extraction des caractéristiques par le backbone DINOv3, les informations sont fusionnées puis transmises au décodeur UperNet afin de générer une carte de segmentation représentant les différents niveaux de dommages observés sur les bâtiments.

Cette architecture permet de tirer profit de la puissance des Vision Transformers pour l'extraction des caractéristiques tout en bénéficiant des capacités de segmentation multi-échelle offertes par UperNet.

3.3.2 Backbone DINOv3

DINOv3 (Distillation with No Labels version 3) est un modèle Vision Transformer (ViT) pré-entraîné selon une approche d'apprentissage auto-supervisé. Contrairement aux méthodes supervisées classiques, DINOv3 apprend des représentations visuelles à partir de grandes quantités d'images sans nécessiter d'annotations manuelles.

Le rôle du backbone DINOv3 dans notre architecture est d'extraire des caractéristiques visuelles de haut niveau à partir des images satellitaires. Grâce à son mécanisme d'attention, il est capable de capturer à la fois les détails locaux des bâtiments et le contexte global de la scène.

Dans ce projet, le backbone DINOv3 est utilisé comme extracteur de caractéristiques afin de fournir au décodeur des représentations robustes et discriminantes nécessaires à la détection des dommages.

3.3.3 Décodeur UperNet

UperNet (Unified Perceptual Parsing Network) est une architecture de segmentation sémantique conçue pour exploiter efficacement les caractéristiques extraites par des réseaux profonds ou des Vision Transformers.

Le décodeur repose principalement sur deux mécanismes complémentaires :

- Le Feature Pyramid Network (FPN), permettant de fusionner les informations provenant de différents niveaux de résolution ;
- Le Pyramid Pooling Module (PPM), permettant de capturer le contexte global de l'image à plusieurs échelles.

Grâce à cette combinaison, UperNet est capable de prendre en compte simultanément les détails locaux et les informations contextuelles de la scène observée.

Dans le cadre de notre projet, le décodeur reçoit les caractéristiques extraites par DINOv3 et génère une carte de segmentation associant chaque pixel à une classe de dommage.

Les classes considérées sont :

- No Damage ;
- Minor Damage ;

- Major Damage ;
- Destroyed.

3.3.4 Pipeline de prédiction

Le pipeline de prédiction commence par le chargement des images pré-catastrophe et post-catastrophe. Les images sont ensuite redimensionnées à une taille de 512×512 pixels puis normalisées à l'aide des paramètres ImageNet utilisés lors du pré-entraînement de DINOv3.

Les images prétraitées sont ensuite fournies au modèle ONNX qui produit une sortie de dimension $(1, 4, H, W)$ correspondant aux logits associés aux quatre classes de dommages.

Une fonction Softmax est appliquée afin de convertir ces logits en probabilités. Pour chaque pixel, la classe possédant la probabilité la plus élevée est sélectionnée comme prédiction finale.

Un seuil de confiance est ensuite utilisé afin d'identifier les pixels dont la prédiction est jugée insuffisamment fiable. Les pixels présentant une confiance inférieure au seuil défini sont affectés à la classe Background.

Enfin, les prédictions sont comparées aux masques de référence du dataset xBD afin d'évaluer les performances du modèle à l'aide des métriques Accuracy et F1-score.

3.3.5 Calibration des probabilités

Les probabilités produites par un réseau de neurones ne reflètent pas toujours fidèlement le niveau réel de confiance des prédictions. Un modèle peut par exemple attribuer une probabilité très élevée à une classe tout en étant incorrect.

La calibration des probabilités vise à corriger ce phénomène afin que les probabilités prédites soient mieux alignées avec les performances réelles du modèle.

Dans ce projet, une étape de calibration a été étudiée afin d'améliorer l'interprétation des probabilités issues de la couche Softmax. Cette opération permet d'obtenir des scores de confiance plus fiables et facilite la prise de décision lors de la classification des dommages.

La calibration est particulièrement importante dans les applications liées à la gestion des catastrophes, où la fiabilité des prédictions peut avoir un impact direct sur l'évaluation des dégâts et l'organisation des interventions.

3.4 Métriques d'évaluation

Afin d'évaluer les performances du modèle de classification des dommages, deux métriques principales ont été utilisées : l'Accuracy et le F1-Score. Ces métriques sont calculées en comparant les prédictions du modèle aux masques de référence du dataset xBD.

3.4.1 Accuracy

L'Accuracy mesure la proportion de prédictions correctes parmi l'ensemble des pixels évalués.

Elle est définie par :

$$Accuracy = \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total de prédictions}}$$

Dans le cadre de ce projet, l'Accuracy est calculée uniquement sur les pixels appartenant aux bâtiments afin d'évaluer la capacité du modèle à attribuer correctement les niveaux de dommages.

Une valeur élevée d'Accuracy indique que le modèle prédit correctement la classe d'un grand nombre de pixels.

3.4.2 F1-Score

Le F1-Score est une métrique qui combine la précision (Precision) et le rappel (Recall) en une seule mesure.

Il est défini par la relation :

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Le F1-Score est particulièrement adapté aux problèmes où les classes sont déséquilibrées, comme dans le dataset xBD où certaines catégories de dommages sont moins représentées que d'autres.

Dans cette étude, le F1-Score pondéré (*Weighted F1-Score*) a été utilisé. Cette version tient compte de la proportion de chaque classe dans le dataset et fournit ainsi une évaluation plus représentative des performances globales du modèle.

Plus la valeur du F1-Score est proche de 1, meilleures sont les performances de classification.

Les métriques ont été calculées uniquement sur les pixels appartenant aux bâtiments, les

pixels de fond étant exclus de l'évaluation.

Chapitre 4

Résultats expérimentaux et application développée

4.1 Environnement expérimental

Les expérimentations ont été réalisées sur un ordinateur équipé d'un processeur AMD Ryzen 5 PRO sous le système d'exploitation Windows. Le développement et les tests ont été effectués en langage Python à l'aide de l'environnement Visual Studio Code.

Le modèle utilisé est une version exportée au format ONNX afin de faciliter son déploiement et son exécution. Les expérimentations ont porté sur la détection et la classification des bâtiments endommagés à partir d'images satellitaires du dataset xBD.

Les images ont été redimensionnées à une résolution de 512×512 pixels avant leur introduction dans le modèle.

4.2 Bibliothèques utilisées

Les expérimentations ont été réalisées à l'aide de plusieurs bibliothèques Python :

- **ONNX Runtime** : chargement et exécution du modèle de Deep Learning exporté au format ONNX ;
- **NumPy** : manipulation des tableaux numériques et traitement des données ;
- **Pillow (PIL)** : lecture, redimensionnement et prétraitement des images ;
- **Matplotlib** : visualisation et sauvegarde des résultats expérimentaux ;
- **Scikit-learn** : calcul des métriques d'évaluation, notamment le F1-Score ;
- **OS** : gestion des fichiers et parcours automatique des dossiers contenant les images et les masques.